

GSM8K XML 1024 Tokens 实验分析

目标

这份文档总结当前这轮 GSM8K xml + 自定义评估器 实验。配置如下：

- max_new_tokens=1024
- limit=300
- Base 与 SFT 使用 greedy decoding
- XML-style prompting + 项目自定义答案提取与错误归因

本文仅基于这轮 1024 tokens 实验的结果展开分析。

结果范围

已完成的运行：

- Base：已完成
- SFT：已完成
- GRPO：已完成

实验设置

- 数据集：gsm8k test parquet
- Prompt 风格：xml
- 样本数：300
- 生成长度：1024
- 设备：mps
- 本文比较口径：greedy decoding

对应结果文件：

- evaluation/results/base_gsm8k_xml_1024_300.json
- evaluation/results/sft_gsm8k_xml_1024_300.json
- evaluation/results/grpo_gsm8k_xml_1024_300_greedy.json

结果

指标定义

- accuracy：宽松正确率。评估器会先尝试提取显式最终答案。如果没有，再回退到较宽松的启发式提取，例如 boxed、Final answer、最后一行或最后一个数字，然后与 gold answer 做等价比较。
- strict_accuracy：严格正确率。只有当模型明确给出可识别的最终答案时才计为有效预测，再与 gold answer 做等价比较。它更强调答案是否被清晰、规范地落出来。
- content_accuracy：内容正确率。若 accuracy 已经判对，则记为正确。否则只要输出文本中出现了与 gold answer 一致的数字内容，也记为正确。它更适合衡量“内容上已经做出来了，但最终答案没有稳定落好”的情况。

核心指标

Model	accuracy	strict_acc	content_acc	format_cond_acc	trunc_rate
Base	14.00%	1.67%	26.67%	9.80%	81.00%
SFT	14.67%	8.00%	47.67%	32.43%	90.00%

Model	accuracy	strict_acc	content_acc	format_cond_acc	trunc_rate
GRPO	19.33%	19.33%	31.33%	19.59%	91.00%

输出质量指标

说明：这组表头较长。若导出到 PDF，可将其理解为：

- avg_word_count：平均词数
- avg_reasoning_steps：平均推理步数
- repetition_rate：重复率
- avg_repetition_ratio：平均重复占比
- degeneration_rate：退化率

Model	avg_word_count	avg_reasoning_steps	repetition_rate	avg_repetition_ratio	degeneration_rate
Base	513.9	4.41	83.33%	0.7384	83.67%
SFT	633.0	4.80	70.67%	0.2335	70.67%
GRPO	452.7	2.49	85.00%	0.4395	85.00%

错误分类

说明：错误类型包括：

- degeneration
- truncation
- computation_error
- format_only_error
- reasoning_error

Model	correct	degeneration	truncation	computation_error	format_only_error	reasoning_error
Base	42	218	9	27	2	2
SFT	44	185	67	3	1	0
GRPO	58	206	36	0	0	0

ARC-Easy: general capability check

为了补充 Topic 1 里“RL 是否提升数学能力但伤害 general capability”这个问题，这里再加入一个轻量的通用 benchmark 检查。

ARC-Easy 使用 lm-eval-harness, limit=300。其中：

- Base 与 GRPO 使用完整模型路径
- SFT 使用 Base + LoRA adapter 口径跑通

Model	acc	acc_norm
Base	59.00%	56.67%
SFT	56.00%	56.00%
GRPO	55.67%	55.67%

这组结果说明：

- Base 仍然最好
- SFT 与 GRPO 都略低于 Base
- 但三者差距不大，更像是轻微回落，而不是明显的 general capability 崩塌

因此，当前更稳妥的结论是：

- SFT 和 GRPO 没有在 ARC-Easy 上带来通用能力提升
- 它们的增益更集中在数学或协议相关行为上
- 目前也没有证据表明它们造成了特别严重的通用能力损伤

主要发现

1. GRPO 在 top-line accuracy 和 strict_accuracy 上最好

如果先看最直接的结果排序：

- accuracy: GRPO (19.33%) > SFT (14.67%) > Base (14.00%)
- strict_accuracy: GRPO (19.33%) > SFT (8.00%) > Base (1.67%)

这说明在当前这套 GSM8K XML 1024 评测下，GRPO 最擅长把答案落成评估器可以直接识别的形式。

2. SFT 的 content_accuracy 最高，说明内容层面仍然最强

如果看 content_accuracy，排序会变成：

- SFT: 47.67%
- GRPO: 31.33%
- Base: 26.67%

这说明 SFT 仍然最容易在输出中生成正确答案内容，即使这些内容并不总能稳定地落成最终得分。

因此，GRPO 的领先主要体现在最终答案的可提取性和协议化表达上，而 SFT 的优势更多体现在内容本身。

这里需要补充一点：content_accuracy 更偏向“正文里有没有出现正确答案”，而不是“最终答案格式是否规范”。

评估器会先看 accuracy 是否正确；若没有判对，再检查整段输出中是否出现与 gold answer 一致的数字内容。

这正好解释了为什么 GRPO 的 strict_accuracy 很高，但 content_accuracy 仍低于 SFT：

- GRPO 更擅长把答案按 <answer> / \boxed{...} 的结构化形式交出来
- SFT 更擅长在长推理正文里写出正确答案内容，即使最终落点不够稳定

因此，更准确的理解是：GRPO 更像是在提升“按协议交卷”的能力，而 SFT 更像是在提升“把题目内容做出来”的能力。

3. GRPO 几乎完全学会了这套 XML / boxed 答案协议

GRPO 的格式相关指标非常高：

- strict_accuracy = 19.33%
- explicit_final_answer_rate = 98.67%
- has_think_rate = 98.67%
- has_answer_rate = 98.67%
- has_single_boxed_rate = 51.00%

同时，GRPO 的答案提取来源几乎完全来自结构化答案：

- boxed: 263

- answer_tag: 33
- last_number: 4

这说明 RL 训练显著强化了模型对 <think> / <answer> / \boxed{...} 这一类协议的遵循。

4. SFT 和 GRPO 分别代表两种不同的优势

从三模型对比来看：

- SFT：内容更强，content_accuracy 最高，重复率和退化率也最低
- GRPO：答案落地更强，accuracy 与 strict_accuracy 最高
- Base：在这轮实验里整体最弱，尤其在严格答案落地上明显落后

这意味着 SFT 与 GRPO 的改进方向并不相同：

- SFT 更像是在提升“题做出来”的概率
- GRPO 更像是在提升“把答案按协议交出来”的概率

4.1 一个轻量验证：GRPO 的提升主要来自格式覆盖率，而不是更高的格式内正确率

如果把“会不会按协议交卷”和“交卷后答得准不准”拆开看，这个结论会更清楚。

Model	explicit answer count	strict correct	format_conditioned_accuracy
Base	51	5	9.80%
SFT	74	24	32.43%
GRPO	296	58	19.59%

这张表说明：

- GRPO 几乎把所有样本都变成了“有显式终答案”的样本
- 但在这些已经按格式交卷的样本里，SFT 的正确率其实更高

因此，一个更直接的解释是：

- GRPO 的 strict_accuracy 提升，主要来自格式覆盖率被大幅拉高
- 它并不意味着 GRPO 在“已经形成结构化终答案之后”的内容正确率也全面超过了 SFT

5. 三个模型都仍然受到严重 truncation 影响

即使 max_new_tokens=1024，三个模型的截断率仍然都很高：

- Base: 81%
- SFT: 90%
- GRPO: 91%

这说明当前评测仍然同时受到以下因素影响：

- 数学内容是否正确
- 最终答案是否及时落地
- 输出是否被截断
- 格式是否可提取

因此，这个 benchmark 不能被简单理解为“纯数学能力排行”。

6. GRPO 并没有在推理质量上全面胜过 SFT

虽然 GRPO 的 top-line 得分最好，但它并不在所有行为指标上最强。

例如：

- GRPO 的 content_accuracy 低于 SFT
- GRPO 的 repetition_rate 与 degeneration_rate 都高于 SFT
- GRPO 的平均推理步数更少，输出更短

这更像是在说明：

- GRPO 学会了更高强度的协议化收尾
- 但 SFT 仍然保留了更丰富的解题内容

解释

基于这轮 1024-token GSM8K xml 实验，可以得到如下总结：

- GRPO 在 accuracy 与 strict_accuracy 上最好
- SFT 在 content_accuracy 上最好
- GRPO 的优势主要来自更强的答案协议遵循与可提取性
- SFT 的优势主要来自更强的内容生成能力

从这轮实验本身出发，更自然的结论是：

GRPO 最擅长“按当前协议把答案交出来”，SFT 最擅长“把题目内容做出来”。

因此，这套结果不应被读成单一维度上的绝对强弱，而更适合被解释为三者存在：

- 内容生成
- 答案落地
- 格式遵循

这三个维度上的不同取舍。

这个 Benchmark 实际在测什么

这个 benchmark 是有价值的，但它的含义需要说清楚。

这里的分数混合了多种因素：

- 数学正确性
- XML 风格答案格式
- 最终答案是否足够早地落下来
- 固定 token budget 下的 truncation
- 自定义答案提取逻辑

因此，更准确的理解应该是：

- 它是一个针对项目 XML 协议下生成行为的诊断型 benchmark
- 它不是一个纯粹、独立的数学能力分数

训练数据生成方式可能带来的影响

从 GenAI_final_project_data 里的可见数据生成逻辑看，SFT 训练数据的构造方式很可能让模型在当前这类 GSM8K 自定义评测里表现更好。

这里的关键不是 XML 标签本身，而是训练数据被系统性地推向了以下风格：

- 长推理

- tutor-style 解题过程
- 明确的最终答案落地
- \boxed{...} 形式的终答案表达

phase_a_manifest.json 里明确要求：

- require_any_r1_solution: true
- min_r1_solution_chars: 200

这说明进入下游训练管道的样本，至少需要带有一条足够长的 r1_solution。这种过滤会天然偏向：

- 更完整的逐步推理
- 更长的数学讲解
- 较少的短答案、短收尾样本

此外，StageA.ipynb 里导出训练样本时，会对解答做额外的终答案补全：

- 如果解答里没有 \boxed{...}，就在末尾追加 \boxed{final_answer_norm}
- alpaca output 还会额外保留一行 Final answer: {final_answer_norm}

这意味着训练目标会反复强化两类行为：

- 把较长的数学推理完整写出来
- 在结尾显式落一个可提取的标准答案

这和当前 SFT 在 GSM8K XML 1024 里的表现是一致的：

- content_accuracy 明显高于 Base
- strict_accuracy 明显高于 Base
- 输出更长
- 但也更容易被截断

因此，一个合理的解释是：

SFT 数据生成方式确实可能帮助模型在 GSM8K 这类较基础的数学题上写出更多正确内容，并更频繁地显式给出终答案。

这会直接抬高：

- content_accuracy
- strict_accuracy

不过，这个现象不应被解释成“模型学会了 XML 协议本身”。

原因是当前结果里：

- has_think_rate 仍然极低
- has_answer_rate 基本为 0
- exact_xml_boxed_rate 仍然为 0

这说明 SFT 学到的更像是：

- 数学讲解式回答
- boxed / Final answer 风格的终答案表达

而不是严格遵循 <think> ... </think><answer> ... </answer> 的 XML 模板。

所以，更准确的说法是：

训练数据生成方式很可能提升了 SFT 在当前自定义 GSM8K 评测中的内容表现和答案落地表现，但这种提升主要来自长推理 XML 标签协议的对齐。

Failure Modes

结合三模型输出和错误归因，本轮实验里最主要的 failure modes 可以概括为四类：

1. degeneration 仍然是最大头。三个模型的退化率都很高，说明很多错误并不是单纯“不会做”，而是输出后段进入重复。
2. truncation 依然严重。即使 max_new_tokens=1024，三个模型的截断率仍在 81% 到 91% 之间，说明 token budget 仍在显著影响最终得分。
3. protocol adherence 与 content correctness 明显分离。GRPO 更强的是 <answer> / \boxed{...} 这类协议化收尾，SFT 更强的是正文里写出正确内容。
4. format drift 主要发生在 Base 和 SFT 上。它们常常能写出某种终答案风格，但并不稳定遵循当前 XML 协议；GRPO 则更容易出现“格式对了、内容未必对”的现象。

Limitations

这轮结果已经能较好说明 Base / SFT / GRPO 在数学生成行为上的差异，但仍有几项限制需要明确：

- 当前虽然补充了 ARC-Easy 这一项 general benchmark，但 general capability 部分仍只基于单个、相对轻量的任务，证据还不算很宽。
- GSM8K XML 分数混合了内容正确性、答案落地、格式遵循和 truncation 等多个因素，因此不应被直接解释为纯数学能力排行。
- 目前还没有完成 data filtering sensitivity 的对照实验，因此关于 SFT 数据筛选策略的判断仍主要是机制性解释，而不是严格 ablation 结论。

结论

对于这轮 1024 实验，最简洁的结论是：

1. GRPO 在 accuracy 和 strict_accuracy 上最好，说明它最擅长按当前协议稳定交出可提取答案。
2. SFT 在 content_accuracy 上最好，说明它在内容层面仍然最容易生成正确答案。
3. 在 ARC-Easy 上，Base 仍然略好于 SFT 和 GRPO，说明 post-training 没有带来通用能力提升，但目前也只看到轻微回落。
4. 三个模型都仍然受到严重 truncation 影响，因此当前结果更适合解释为“生成行为与答案落地”的对比，而不是纯数学能力。