

数据选择说明文档

阶段 A：数据选择与清洗说明 (Stage A: Data Selection & Curation)

1. 概述 (Overview)

本阶段旨在为 **DeepSeek-R1 风格的数学推理训练流水线** 构建高质量的冷启动数据集。我们选择了 **DeepMath-103K** 数据集作为基础，通过实施一系列**可解释的过滤规则 (Explicit Filtering Rules)**，剔除了噪声大、模糊或格式不规范的样本，确保剩余数据具备**高可验证性**，以支持后续的监督微调 (SFT) 及基于验证器的强化学习 (RL)。

- 原始数据源:** AI-ModelScope/DeepMath-103K (共 103,022 条样本)
- 处理后数据量:** 100,891 条样本
- 数据保留率:** 97.93%
- 输出格式:** Parquet (含完整元数据) 及 Alpaca 格式 JSONL (适配 llama-factory)

2. 过滤策略与规则 (Filtering Strategy & Rules)

为了平衡数据的多样性与质量，我们定义了以下核心过滤维度，并记录了每条样本被剔除的首要原因：

2.1 模糊性问题剔除 (Ambiguity Removal)

- 目标:** 移除无法通过自动验证器判断对错的问题（如证明题、开放性问题）。
- 规则:** 使用正则表达式匹配包含 "prove or disprove", "true or false", "does there exist", "open problem" 等关键词的题干。
- 效果:** 剔除 2,050 条样本 (占比约 1.99%)。这是最主要的剔除来源，显著提升了数据集的可验证性。

2.2 长度控制 (Length Control)

- 目标:** 去除信息缺失的过短题目和超出小模型上下文窗口的过长题目。
- 规则:**
 - 题干长度 < 30 字符 (`min_question_chars`)
 - 题干长度 > 4000 字符 (`max_question_chars`)
- 效果:** 剔除 75 条样本 (73条过短 + 2条过长)。

2.3 难度筛选 (Difficulty Control)


- **目标:** 排除难度标签异常（如占位符 -1）或超出预设范围的样本。
- **规则:** 难度值需在 $[1.0, 10.0]$ 区间内。
- **效果:** 剔除 4 条样本。

2.4 答案格式规范化 (Answer Format Enforcement)

- **目标:** 确保所有样本拥有清晰、非空的最终答案，以便 RL 阶段计算 **Exact Match (EM)** 奖励。
- **规则:**
 - `final_answer` 不能为空或超过 512 字符。
 - **标准化处理:** 去除多余空白，剥离外层 `$...$` 符号。
 - **Boxed 补全:** 对于解题过程 (`r1_solution`) 中缺失 `\boxed{}` 标记的样本，自动在末尾追加 `\boxed{normalized_answer}`。
- **效果:** 剔除 2 条空答案样本；100% 保留样本已完成格式标准化。

3. 数据分析与可视化 (Data Analysis & Visualization)

3.1 分布变化对比



通过对比过滤前后的直方图，我们观察到：

- **难度分布 (Difficulty Distribution):**
 - 过滤后，低质量的低难度样本被少量清除，整体分布仍保持多峰形态（集中在难度 5-6），符合数学数据集的自然分布。
 - 保留了从基础运算到高阶竞赛题的完整跨度，有利于模型课程学习（Curriculum Learning）。
- **题干长度分布 (Problem Length Distribution):**
 - 成功截断了左侧的极短尾部（<30 chars），消除了因题目描述不清导致的噪声。

- 主体分布集中在 100-400 字符之间，非常适合 `Qwen2.5-0.5B` 或 `Llama-3.2-1B` 等小参数量模型的上下文窗口。

3.2 敏感性分析 (消融实验)

我们对难度阈值 `min_difficulty` 进行了敏感性扫描，结果如下：

最小难度阈值 (\$min_difficulty\$)	保留样本数 (Kept)	保留率 (Rate)	分析
1.0 (默认)	100,891	97.93%	基准设置： 保留了绝大多数有效数据，仅剔除明显噪声。
3.0	100,576	97.63%	影响微乎其微，说明极低难度样本本身较少或大多符合其他规则。
5.0	86,894	84.35%	显著下降： 若只保留中等以上难度，将损失约 15% 数据，可能影响基础格式学习。
7.0	31,413	30.49%	剧烈下降： 仅保留高难竞赛题会导致数据量不足，易导致过拟合。

结论: 选择 $min_difficulty = 1.0$ 是最优策略，能在保证数据量的同时，通过其他规则（如模糊性过滤）有效控制质量。

4. 数据交付物 (Deliverables)

本阶段产出了以下文件，供 Stage B (SFT) 和 Stage C (RL) 直接使用：

- `deepmath_phase_a.parquet` :
 - 包含所有原始列及新增的 `final_answer_norm`。
 - 三条推理链 (`r1_solution_1/2/3`) 均已强制补全 `\boxed{answer}` 格式，便于后续提取推理路径或计算格式奖励。
- `deepmath_phase_a_alpaca.jsonl` :
 - 转换为 `llama-factory` 兼容的 Alpaca 格式 (`instruction`, `input`, `output`)。
 - `output` 字段由最长推理链构成，并附带 `Final answer: ...` 行，明确对齐标准答案。
- `phase_a_manifest.json` :

- 记录了完整的过滤配置 (`FilterConfig`)、统计计数及数据处理逻辑，确保实验**可复现**。

5. 下一步计划 (Next Steps)

- **Stage B (SFT):** 使用生成的 `jsonl` 文件对基座模型（如 `Qwen2.5-0.5B`）进行冷启动微调，观察 Loss 收敛情况及在 `GSM8K` 上的初步表现。
- **Stage C (RL):** 利用数据中标准化的 `\boxed{}` 答案设计 **Exact Match** 奖励函数，结合 **格式奖励**，实施 GRPO 算法进一步提升推理准确率。